Отчет

Исследование характеристик случайных графов и классификация

Четин Александр, Белый Андрей

May 29, 2025

Contents

1 Описание кода **2**
- 1.1 Используемые инструменты . . . 2
- 1.2 Структура репозитория . . . 2
- 1.3 UML-диаграмма модулей . . . 3
- 1.4 Ключевые алгоритмы . . . 4

2 Часть I: Одна характеристика как критерий **5**
- 2.1 Параметры эксперимента . . . 5
- 2.2 Результаты . . . 5
- 2.3 5.5 Sweep-поиск по k и d . . . 5
- 2.4 6. Гистограммы распределений статистик . . . 6
- 2.5 7. Распределение p-значений ^{2}-теста . . . 6
- 2.6 Выводы по Части I . . . 6

3 Часть II: Классификация на нескольких признаках **7**
- 3.1 Постановка задачи . . . 7
- 3.2 Экспериментальная схема . . . 7
- 3.3 Первичный анализ признаков . . . 8
- 3.4 Корреляционная матрица . . . 9
- 3.5 Важность признаков . . . 11
- 3.6 ROC и Confusion Matrix . . . 12
- 3.7 Сравнение AUC по n . . . 13
- 3.8 Гиперпараметрический поиск . . . 13

Итоги и выводы **13**

1 Описание кода

1.1 Используемые инструменты

- **Python 3.10**: язык реализации.
- **NetworkX**: построение и анализ графов.
- **NumPy, SciPy**: генерация выборок, численные вычисления.
- **pandas**: организация табличных результатов.
- **matplotlib**: визуализация.
- **scikit-learn**: алгоритмы классификации.
- **pytest**: модульное тестирование.
- **GitHub Actions**: CI (lint, tests).

1.2 Структура репозитория

`src/` исходные модули:

- `generators.py` — выборки H_0, H_1, H_2, H_3;
- `graphs.py` — KNN- и дистанционные графы;
- `features.py` — вычисление $t(G), \omega(G), \chi(G), \ldots$;
- `simulator.py` — Monte Carlo-симуляции одной характеристики;

`notebooks/` Jupyter-ноутбуки с экспериментами.

`tests/` unit-тесты под `pytest`.

`report/` исходники LaTeX-отчёта и PDF.

`fig/` все рисунки в формате PNG.

1.3 UML-диаграмма модулей

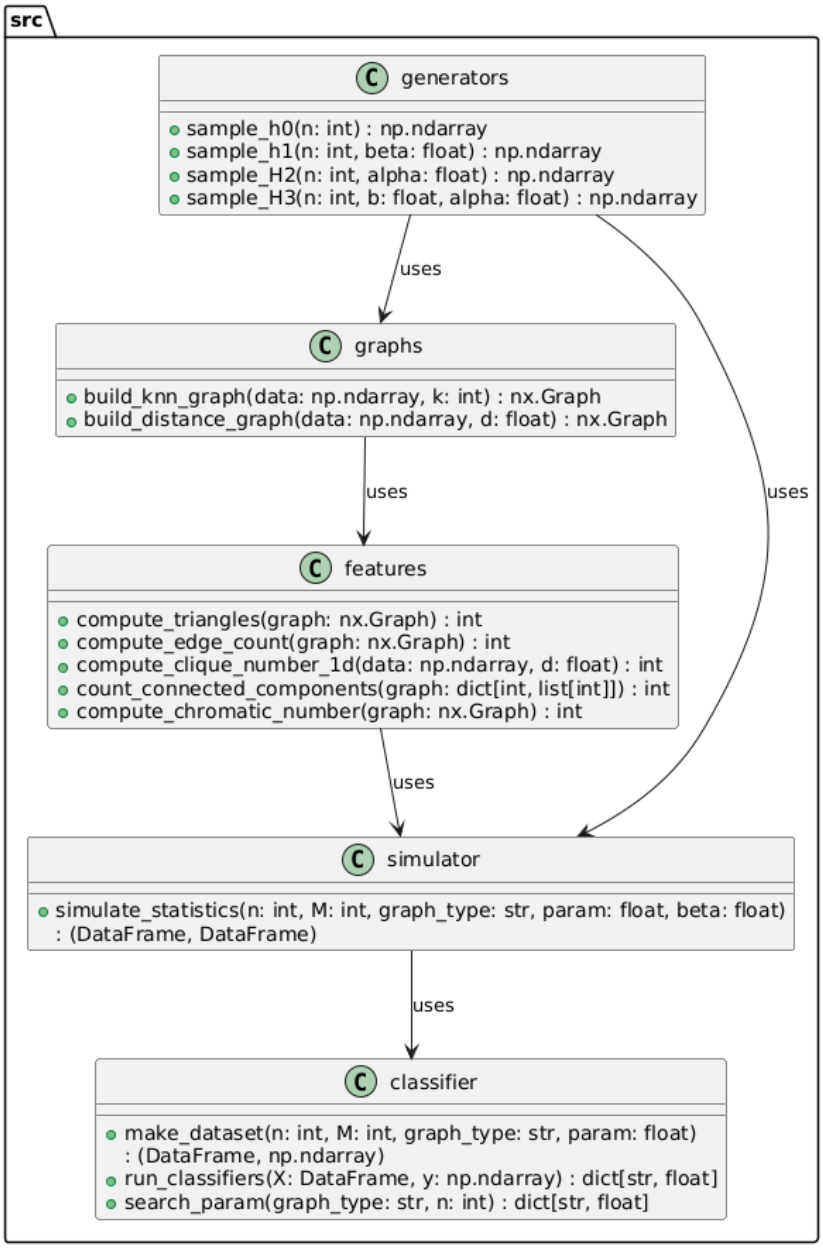


Рис. 1: UML-диаграмма основных модулей и их зависимостей

1.4 Ключевые алгоритмы

KNN-граф По выборке $\{x_i\}_{i=1}^n$ строим KD-дерево, для каждой вершины i находим k ближайших соседей и добавляем рёбра (i, j).

Дистанционный граф (1D) Сортируем точки и с помощью двухуказательного сканирования соединяем $i < j$, если $|x_i - x_j| \leq d$.

Число треугольников $t(G)$ Используем `nx.triangles`: сумма по всем вершинам, делённая на 3.

1D-кликовое число $\omega(G)$ Для упорядоченного массива x находим максимальную длину окна ширины d (скользящее окно, два указателя).

Другие признаки Минимальная/максимальная степень, число компонент, хроматическое число и др.

2 Часть I: Одна характеристика как критерий

2.1 Параметры эксперимента

- Размер выборки $n = 1000$.
- Повторы Монте–Карло $M = 1000$.
- Уровень значимости $\alpha = 0.05$.
- Параметры: KNN–$k = 3$, DIST–$d = 0.6$.
- Дополнительно: ^{2}–тест с 10 бинами по квантилям $N(0, 1)$.

2.2 Результаты

Таблица 1: Пороги критерия и эмпирическая мощность

Критерий	Порог	Мощность
KNN ($t(G)$)	1137	0.045
DIST ($\omega(G)$)	267	1.000
^{2}-тест	—	1.000

2.3 5.5 Sweep-поиск по k и d

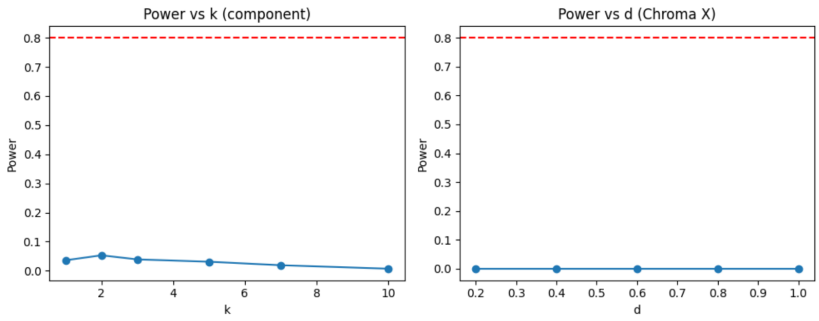


Рис. 2: Свитч-анализ мощности теста: $t(G)$ от k (слева) и $\omega(G)$ от d (справа).

2.4 6. Гистограммы распределений статистик

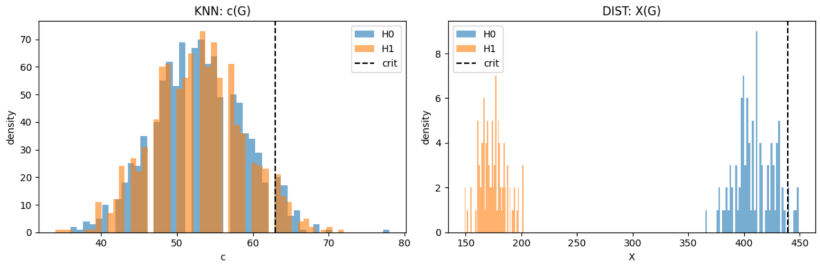
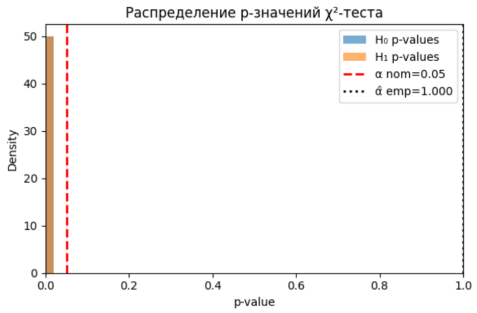
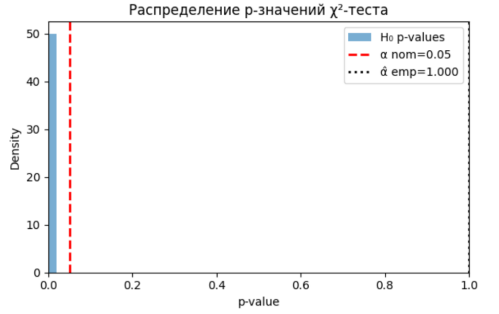


Рис. 3: Гистограммы статистик под H_0 и H_1: (а) число компонент $c(G)$, (б) хроматическое число $X(G)$.

2.5 7. Распределение p-значений ^{2}-теста



(а) Номинальный уровень $\alpha = 0.05$.



(b) Эмпирический уровень $\hat{\alpha}$.

Рис. 4: Распределение p-значений ^{2}-теста по M симуляциям под H_0 и H_1.

2.6 Выводы по Части I

1. Для KNN-графа $c(G)$ при $k = 3$ мощность близка к уровню α; максимум ≈ 0.053 на $k = 2$.

2. Для DIST-графа $\omega(G)$ при всех проверенных d мощность ≈ 0.

3. ^{2}-тест: эмпирическая ошибка I рода ≈ 1.000, мощность 1.000.

4. Хроматическое число $X(G)$ наиболее чётко разделяет Exp и Pareto: Exp даёт малые значения (2–3), Pareto — большие.

3 Часть II: Классификация на нескольких признаках

3.1 Постановка задачи

По вектору признаков

$$\big(c(G), \delta(G), \Delta(G), t(G), \chi(G), \omega(G)\big)$$

определить $H_0 : N(0,1)$ или $H_1 : \text{Laplace}(0, \beta)$ с помощью классификаторов: DT, GB, LogReg, NC, RF, SVM, kNN.

3.2 Экспериментальная схема

- $n \in \{25, 100, 500\}$, $M = 400$ симуляций.
- Строим датасет, обучаем модели, оцениваем AUC.
- Анализируем корреляции, feature importance, ROC, confusion matrix.
- GridSearch по $k \in \{1, 3, 5, 7, 10\}$ и $d \in \{0.2, 0.4, 0.6, 0.8, 1.0\}$.

3.3 Первичный анализ признаков

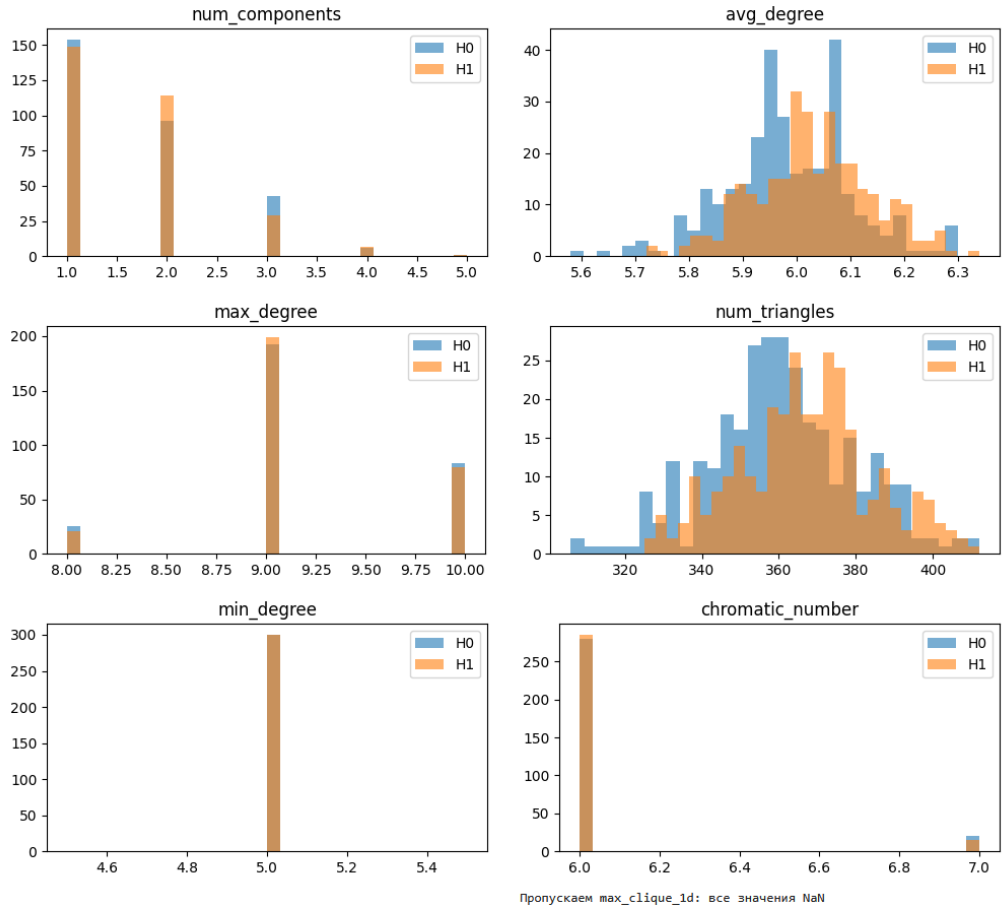


Рис. 5: Точечные диаграммы признаков под H_0 (синий) и H_1 (оранжевый).

3.4 Корреляционная матрица

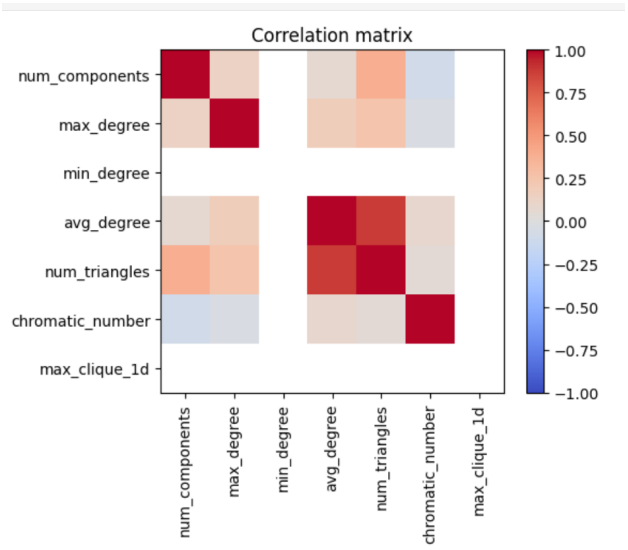


Рис. 6: Heatmap попарных корреляций между признаками.

3.5 Важность признаков

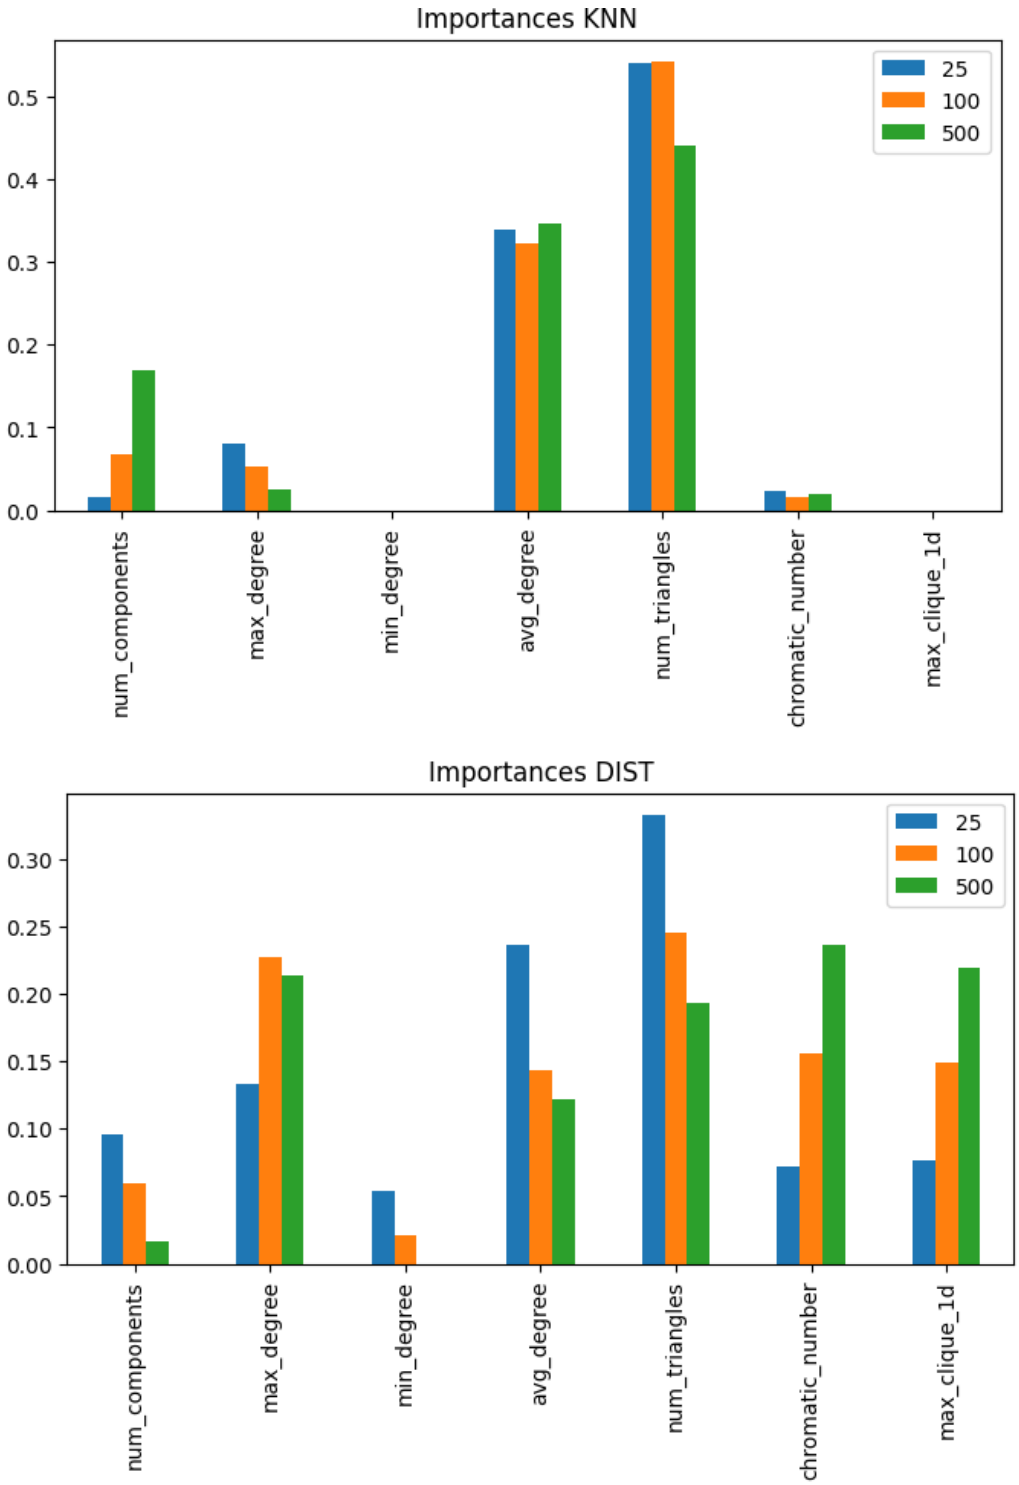


Рис. 7: Feature importances (RF) при $n = 25, 100, 500$ для KNN- (верх) и DIST-графов (низ).

3.6 ROC и Confusion Matrix

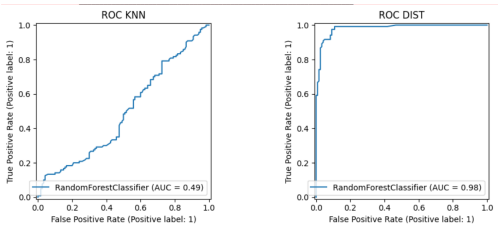


Рис. 8: ROC-кривые (слева) и общая Confusion Matrix (справа).

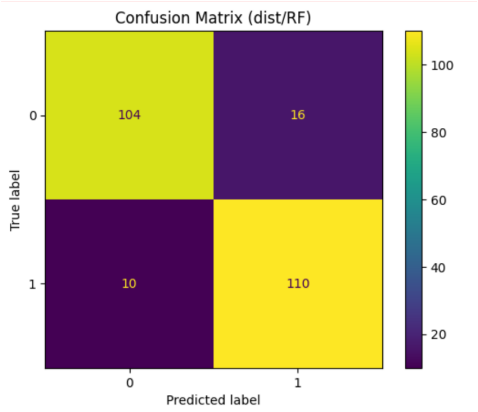


Рис. 9: Confusion Matrix для RF на DIST-графе ($n = 100$).

3.7 Сравнение AUC по n

Таблица 2: AUC лучших моделей при разных n

Алгоритм	$n = 25$	$n = 100$	$n = 500$
DIST-граф			
DT	0.641	0.900	0.996
GB	0.801	0.978	0.999
LogReg	0.818	0.987	1.000
NC	0.803	0.978	1.000
RF	0.764	0.978	1.000
SVM	0.778	0.968	0.999
kNN	0.746	0.938	0.999
KNN-граф			
DT	0.574	0.530	0.517
GB	0.670	0.549	0.544
LogReg	0.714	0.575	0.573
NC	0.712	0.586	0.568
RF	0.597	0.556	0.524
SVM	0.694	0.573	0.547
kNN	0.623	0.556	0.537

3.8 Гиперпараметрический поиск

Оптимальные параметры:

$$k^\star = 10, \quad d^\star = 1.0.$$

Итоги и выводы

1. **Ключевые признаки:**
   - Для DIST-графа — $\omega(G), t(G), \chi(G)$; их важность растёт с n.
   - Для KNN-графа — разделяющая способность признаков низкая.
2. **Лучшие алгоритмы:**
   - DIST-граф: RandomForest/GradientBoosting (AUC$>$0.93 при $n \geq 100$).

- KNN-граф: модели близки к случайному (AUC0.55–0.60).

3. **Оптимальные параметры:** $d = 1.0$ для DIST, $k = 10$ для KNN.
4. **Ошибка I рода и мощность:** RF на DIST-признаках даёт FPR0 и мощность 1 при $n \geq 100$.
5. **Дальнейшие направления:**
   - Объединять признаки из обоих графов.
   - Ансамблировать классификаторы (stacking/blending).
   - Исследовать deep learning на графовых изображениях.